PROJETO DE PESQUISA DE DOUTORADO

Aprendizado de Preferências para Otimização de Escalas de Médicos em Clínicas de Diagnóstico por Imagem

Thiago Rafael Mariotti Claudio - Número USP: 15611674
Orientadora: Roseli Aparecida Francelin Romero - SCC/ICMC/USP

Dezembro de 2025

Neste projeto de doutorado, propõe-se investigar técnicas de solução alternativas a modelagem clássica de Pesquisa Opercional, procurando integrar Otimização e Inteligência Artificial em um Problema de Alocação e Escalonamento de Médicos em redes multi-clínicas de diagnóstico por imagem. A motivação central reside na necessidade de incorporar preferências implícitas dos profissionais de saúde em modelos de otimização, visando melhorar tanto a satisfação profissional quanto a eficiência operacional através de técnicas pouco exploradas na literatura atual. Têm-se como foco principal a aplicação de Otimização Inversa e Aprendizado de Preferências, buscando desenvolver um *framework* integrado que una essas metodologias com técnicas de Otimização Robusta e Aprendizado de Máquina, afim de captar, compreender e modelar os dados na expectativa de se obter modelos mais precisos e condizentes com a realidade. Como motivação principal para a desenvolvimento e validação do projeto, será utilizada uma base de dados reais oriunda de operações clínicas de ultrassonografia, com a devida autorização das partes envolvidas, permitindo a avaliação empírica das metodologias propostas.

1 Introdução

O setor de saúde privado brasileiro é caracterizado por uma complexa rede de unidades de diferentes vertentes, que buscam atender a população com serviços médicos especializados. Dentro deste contexto, clínicas especializadas em diagnóstico por imagem desempenham papel crucial na detecção de doenças e condições de forma eficaz e antecipada (YASUI et al., 2012), com um volume de 2,4 bilhões de exames realizados em 2023, conforme apontam dados da Medicina S.A. (2024).

Entretanto, unidades do setor privado enfrentam pressão dupla: custos elevados da operação, que, embora venha caindo anualmente (**??**), ainda representam um desafio significativo para a sustentabilidade financeira, aliado a escassez de profissionais qualificados, especialmente médicos especializados em ultrassonografia. Conforme apontam estudos de Liebel et al. (2021), estima-se que a falta de médicos especialistas crie um vácuo desproporcional na oferta de atendimentos, com uma média de 1,99 médicos por 1,51 mil habitantes.

Uma forma de contornar esse desafio se dá pela otimização de escalas de trabalho, especialmente escalas médicas, de forma a maximizar o atendimento sem comprometer a operação, reduzindo os custos de maquinário ocioso (ANSS, 2024). Existem autores, na literatura, que demonstram como a confecção e otimização de escalas médicas podem contribuir para melhorias no volume de atendimento (ROUSSEAU et al., 2002) e no uso eficiente de recursos clínicos, como máquinas de ultrassonografia (ROBINSON; CHEN, 2003).

A alocação manual de médicos, no entanto, é uma tarefa laboriosa, dada sua alta complexidade combinatória, comprovadamente um problema NP-difícil (EVEN et al., 1976). Observa-se portanto, na literatura, o uso de programação matemática como forma modelar o problema observado, e, através de técnicas de otimização, obter-se uma solução satisfatória. Alguns trabalhos, como o de Tasso et al. (2024), aplicado no contexto multi clínico, demonstram a proeficiência da programação matemática para otimização de alocação de médicos, com uma redução de 21% na demanda não atendida em comparação com alocações manuais.

Tais abordagens, no entanto, focam em minimizar demanda não atendida ou equilibrar cobertura, tratando o problema como determinístico com parâmetros fixos. Em prática, o escalonamento em redes de saúde privada é substancialmente mais complexo que o tratado na literatura. A operação real envolve imprevisibilidades: (i) Disponibilidades estruturadas em três categorias distintas: padrão (recorrente), finais de semana e feriados (ambos com regras trabalhistas quanto a escalas); (ii) Eventos que constrangem disponibilidade dos profissionais: férias, congressos; (iii) Preferências implícitas nunca modeladas: médicos possuem preferências reveladas sobre quais clínicas trabalhar (levando em consideração localização e moradia), criando padrões não-aleatórios nas escalas históricas. Além

disso, também observa-se regras estruturais quanto o funcionamento das clínicas, como a não sobreposição de médicos em múltiplas unidades no mesmo dia, e a necessidade de estabilidade nas escalas, evitando mudanças abruptas semana a semana que impactam negativamente a satisfação dos profissionais.

A literatura de otimização em escalonamento de pessoal em saúde é bem estabelecida através de revisões sistemáticas clássicas. Ernst et al. (2004) e Heuberger (2004) consolidam conhecimento acumulado ao longo de décadas sobre o tema. Uma síntese dessa produção demonstra que abordagens metodológicas predominantes focam em dois aspectos principais: minimização de demanda não atendida ou equilíbrio de cobertura entre unidades. Ernst et al. (2004) demonstra que a maioria dos trabalhos utiliza modelos determinísticos onde parâmetros (demanda, disponibilidade) são tratados como fixos e conhecidos.

Entretanto, essa formulação deixa sem exploração um domínio de investigação importante: como aprender as preferências implícitas dos profissionais a partir de escalas históricas e incorporá-las sistematicamente em novos cronogramas. A literatura de otimização matemática não desenvolveu ferramentas específicas para esse fim no contexto de physician rostering, embora técnicas mais gerais de inferência a partir de decisões observadas existam há décadas.

Especificamente, a metodologia de Otimização Inversa permite recuperar funções objetivo desconhecidas a partir de um conjunto de decisões observadas, assumindo que essas decisões foram tomadas de forma otimizada. Ahuja e Orlin (2001) apresentam o framework clássico de Inverse Optimization, onde se inverte o problema tradicional: ao invés de resolver um modelo forward (dado objetivo e restrições, encontre a melhor solução), resolve-se o problema inverso (dadas soluções observadas, deduza qual era o objetivo subjacente). Ahuja e Orlin (2001) demonstram que, sob condições apropriadas, problemas de otimização inversa podem ser reformulados como problemas diretos tratáveis computacionalmente. Heuberger (2004) e Ghobadi e Mahmoudzadeh (2021) expandem essa teoria para problemas combinatoriais e de inferência de regiões viáveis.

A aplicação de Otimização Inversa em contextos de saúde, particularmente para inferir preferências de profissionais em scheduling, permanece não explorada na literatura. Esse vácuo contrasta com a crescente adoção de técnicas de Aprendizado por Preferências em inteligência artificial.

2 Proposta

Mediante investigação na literatura, é notado uma possibilidade volumosa de formas de modelar e solucionar problemas de escalonamento e alocação médica (BERGH et al., 2013). Contraintuitivamente, poucas abordagens considerem a incorporação sistemática de preferências implícitas dos profissionais de saúde (ERHARD et al., 2018), ou se antentem a formulações alternativas para o problema. A presente proposta levanta a possibilidade em abordar, de forma integrada, o escalonamento de médicos em redes multi clínicas especializadas em diagnóstico por imagem, mediante metodologias de Otimização Inversa, Aprendizado de Preferências e Otimização Matemática Robusta. O intuito é desenvolver um *framework* que aprenda automaticamente as preferências implícitas dos profissionais a partir de escalas históricas e incorpore sistematicamente em cronogramas futuros, melhorando simultaneamente eficiência operacional e satisfação profissional (BURDETT et al., 2017).

Em formulações convencionais de problemas similares, especialmente no campo determinístico, dados históricos são comumente relegados a um papel secundário de validação ou avaliação, incorporando tais dados como parâmetros fixos para a entrada do modelo. Em uma proposta alternativa, adotamos que:

(i) escalas históricas codificam informação valiosa sobre preferências dos médicos;

(ii) essas preferências não são capturadas adequadamente apenas por questionários diretos;

(iii) metodologias de otimização inversa permitem recuperar essas preferências de forma sistemática.

Propõe-se, portanto, nesta seção do documento, uma estrutura metodológica em três etapas integradas. Esta primeira etapa envolve a recuperação de funções objetivo de utilidade implícitas para os clínicos através de técnicas de Otimização Inversa aplicadas ao histórico de escalas observadas. Ahuja e Orlin (2001) estabeleceram o *framework* clássico de Otimização Inversa, a partir de um conjunto de soluções observadas $x_1, x_2, \ldots, x_K$ que se presume serem ótimas (ou próximas a ótimas) para um problema de otimização $\min_x c^T x : x \in X$, deduzir o vetor de custos c que tornariam essas soluções ótimas. No contexto deste projeto, interpretamos a alocação histórica como uma solução que reflete implicitamente uma função de utilidade desconhecida do médico.

Portanto, para cada médico i, clínica u, dia d e turno t, formulamos um problema de Otimização Inversa, no qual:

- Soluções observadas: Conjunto de alocações $A_i = \{(u, d, t)$: médico i foi alocado em clínica u, dia d, turno $t\}$ extraído de escalas históricas.
- Objetivo inverso: Recuperar pesos $w_i = (w_{i,u}, w_{i,t})$ que representam as preferências implícitas do médico sobre clínicas e turnos.
- Reformulação: O problema inverso é reformulado como um problema de otimização: minimizar a quantidade de violações à otimalidade das soluções observadas, encontrando pesos w_i que melhor explicam as alocações históricas.

Para isso, é importante definir métricas de avaliação coerentes, de modo que valide satisfatoriamente a etapa proposta, explicando $> 80\%$ da variância nas alocações históricas (via coeficiente de determinação).

Podemos então prosseguir para a etapa de Validação Preditiva de Preferências, que consiste em validar a qualidade das preferências aprendidas através de sua capacidade de predizer alocações futuras não vistas durante o treinamento. É importante validar a proposta mediante o uso de dados históricos reais, bem como validar se, para esse tipo de problema temporal (otimização de escalas), o padrão de preferência se mantém estável.

Para isso, separa-se um conjunto de treinamento para aprender as preferências w_i através de Otimização Inversa (Etapa 1).

No conjunto de teste, para cada médico, predizer quais alocações ele provavelmente aceitaria (aquelas com utilidade $>$ limiar). Comparar com alocações reais observadas através de métricas de acurácia: (i) Precisão: proporção de alocações preditas que foram realmente observadas; (ii) Recall: proporção de alocações observadas que foram preditas; (iii) F1-score: média harmônica de precisão e recall.

Consideramos nessa proposta de projeto atingir o valor F1-score ≥ 0.75 para pelo menos 80% dos médicos, indicando que o modelo de preferências aprendido é preditivo e robusto.

Por fim, realizamos a Integração em Modelo de Otimização Multiobjetivo, etapa que integra as preferências aprendidas ao modelo de otimização existente, transformando-o de um problema determinístico mono-objetivo em um modelo multiobjetivo que equilibra eficiência operacional e satisfação profissional.

Ernst et al. (2004) consolidam a literatura de escalonamento em saúde, identificando três objetivos principais: (i) minimizar demanda não atendida; (ii) maximizar cobertura mínima entre unidades; (iii) minimizar trocas de profissionais entre unidades. Tomando como base o referido trabalho, adicionamos um quarto objetivo: maximizar satisfação profissional baseada em preferências aprendidas. O modelo de otimização multiobjetivo minimiza simultaneamente:

- F_1: demanda não atendida agregada (eficiência);
- F_2: número de trocas de clínicas (estabilidade);
- F_3: penalidade por violação de preferências (satisfação).

Onde $F_3 = \sum_i \sum_u \sum_t (1 - u_i(u,t)) \cdot x_{iut}$, sendo $u_i(u,t)$ a utilidade (preferência) do médico i pela alocação em clínica u e turno t, conforme aprendida na Etapa 1. Abordagem de Resolução: Para um problema multiobjetivo, utilizar o método Epsilon-Constraint: primeiro, resolver para minimizar F_1; em seguida, resolver sujeito à restrição de que $F_1 \leq F_1^* + \epsilon$ enquanto minimiza F_2; por fim, resolver sujeito às restrições anteriores enquanto minimiza F_3. Isso gera um conjunto de soluções Pareto-ótimas representando diferentes *trade-offs* entre objetivos.

Para instâncias pequenas ou medianas, dispõe-se do uso de *solvers* de Programação Inteira Mista - para esta pesquisa, o Gurobi em sua versão licenciada mais atual - que implementam técnicas da literatura de otimização, como *branch-and-bound*. Esses métodos fornecem soluções ótimas comprovadas, úteis como referência (*benchmarking*) para comparação com metodologias alternativas.

2.1 Metodologias alternativas

Devido à complexidade combinatória do problema, inerente à estrutura de decisão, como "vários-para-vários"(múltiplos médicos para múltiplas clínicas), cargas de disponibilidade diferentes (médicos têm certa autônomia para quantos exames atender em um período) e eventos de indisponibilidade (que também incluem férias ou folgas por escala), é proposto a investigação de metodologias alternativas para solução. A seguir pontuam-se algumas possibilidades a serem investigadas:

- **Heurísticas Baseadas em Decomposição:** Técnicas de decomposição particionam o problema original em subproblemas menores e mais tratáveis, resolvendo-os sequencialmente ou iterativamente (WOLSEY, 1998). Para problemas de escalonamento com estrutura temporal e espacial como o presente, abordagens de decomposição são particularmente eficazes ao explorar a estrutura do problema. Exemplos incluem estratégias que relaxam restrições integrais de certos subconjuntos de variáveis enquanto fixam outros iterativamente, ou que partem de uma solução inicial viável e iterativamente liberam subconjuntos de variáveis para re-otimização local, mantendo outras fixas (CORDEAU et al., 2002). Estas técnicas são amplamente reconhecidas na literatura de scheduling hospitalar e rostering de pessoal (ERNST et al., 2004) como mecanismos capazes de gerar soluções de qualidade razoável em tempo computacional viável para instâncias de médio a grande porte.

- **Metaheurísticas:** Metaheurísticas são procedimentos iterativos de alto nível que guiam heurísticas de nível inferior na exploração do espaço de soluções, frequentemente escapando de ótimos locais através de estratégias probabilísticas ou de vizinhança (BLUM, 2003). No contexto de problemas de alocação e scheduling, metaheurísticas como algoritmos genéticos, busca tabu, têmpera simulada e otimização por enxame de partículas têm demonstrado eficácia em gerar soluções de qualidade competitiva. Para o problema de escalonamento multi-clínico proposto, metaheurísticas oferecem flexibilidade para incorporar restrições operacionais específicas (como disponibilidades em categorias distintas e eventos de indisponibilidade) que podem ser difíceis de modelar explicitamente em formulações matemáticas inteiras. A literatura recente em scheduling de pessoal em saúde demonstra que combinações de decomposição com metaheurísticas frequentemente superam abordagens puramente exatas em problemas de grande escala (CHIARANDINI et al., 2006).

2.2 Roteirização

As linguagens C++ e Python serão utilizadas como motivação para implementação e fundamentação técnica do projeto. Ambas partilham de ferramentas de análise de dados, modelagem matemática e integração com *solvers* de otimização. A escolha dessas linguagens se deve à sua robustez, ampla adoção na comunidade científica e disponibilidade de bibliotecas especializadas. A principal ferramenta aplicada durante a pesquisa será o Gurobi, em sua versão licenciada mais atual, embora a possibilidade de uso de ferramentas como CPLEX ou Scipy sejam consideradas, especialmente a titulo de comparação.

O projeto será validado mediante dados operacionais reais de uma rede de clínicas de ultrassonografia em São Paulo. Existe a possibilidade de acesso a uma base de dados, contendo registros históricos dos últimos 3 anos. Essa base é crucial para a validação empírica das metodologias propostas, permitindo a análise de desempenho em cenários reais.

Reitera-se a importância de definir métricas claras para avaliar o sucesso do projeto. As métricas propostas incluem:

- Redução em demanda não atendida;
- Acurácia preditiva das preferências aprendidas;
- Satisfação dos médicos;
- Retenção de médicos.

3 Objetivos da Pesquisa

Neste doutorado pretende-se investigar metodologias de Inteligência Artificial, especificamente Otimização Inversa e Aprendizado de Preferências, aplicadas ao Problema de Alocação e Escalonamento Médicos em redes multi-clínicas. Este problema é fundamental para operações de saúde de grande porte e carece de abordagens que integrem sistematicamente as preferências implícitas dos profissionais em modelos de otimização. A justificativa fundamenta-se em três lacunas observadas:

(1) Lacuna Teórica: A metodologia de Otimização Inversa, consolidada por Ahuja e Orlin (2001) é pouco explorada como forma primária de solução ou proposta, especialmente em problemas de Alocação e Escalonamento, que se beneficiariam da capacidade de inferência das preferências pessoais.

(2) Lacuna Prática: Coleta de preferência por questionários ou entrevistas, além de onerosos, falham em capturar tendências e padrões reais de comportamento. Mediante uso desses dados estruturados em treinamento de modelos de Otimização Inversa, é possível inferir preferências reais a partir de dados históricos de escalas.

(3) Lacuna de Impacto: É comum, especialmente no setor de saúde privada, a busca por soluções que priorizem a esfera operacional em detrimento a satisfação profissional. Ao integrar preferências reais com gestões operacionais, é possível alcançar maior retenção profissional (BARD; PURNOMO, 2005), reduzindo portanto custos associados a rotatividade e absenteísmo; e melhorar a qualidade do serviço através da qualidade de vida do profissional (OLSON; DAVIS, 2020).

Neste projeto, aspiramos integrar técnicas de Otimização Inversa para inferência de preferências com Aprendizado de Máquina e Otimização Robusta, desenvolvendo um framework coerente que combine insights de Inteligência Artificial com métodos rigorosos de otimização matemática. A investigação enfatiza o componente de *learning* (aprender preferências de dados) como elemento central, diferenciando-se de abordagens puramente determinísticas ou baseadas em decomposição-heurística.

Especificamente, os objetivos são:

1. Desenvolver uma metodologia de Otimização Inversa aplicável a contextos multi-unidade de rostering de saúde, recuperando funções de utilidade implícitas para profissionais a partir de escalas históricas.

2. Validar empiricamente que preferências aprendidas via Otimização Inversa produzem cronogramas com satisfação profissional mensurável superior aos cronogramas determinísticos puros, mantendo eficiência operacional comparável ou superior.

3. Propor um *framework* integrado que combine Otimização Inversa, Aprendizado de Preferências e Otimização Multiobjetiva Robusta, demonstrável em dados reais de operações clínicas de ultrassonografia.

No final do doutorado, esperamos propor um *framework* bem fundamentado nas literaturas vigentes que integre explicitamente Pesquisa Operacional e Aprendizado de Máquina, contribuindo tanto à literatura de Inteligência Artificial aplicada quanto aos métodos de Otimização em saúde.

4 Cronograma de Atividades

A seguir, apresenta-se o cronograma para o desenvolvimento das atividades relativas ao projeto em questão. Este cronograma tem como finalidade assegurar o bom desenvolvimento e acompanhamento do projeto. As atividades propostas estão divididas da seguinte maneira:

- A1. Obtenção dos créditos em disciplinas.
- A2. Levantamento bibliográfico e pesquisa em trabalhos correlatos ao projeto proposto.
- A3. Obtenção de créditos e práticas disciplinares em docência (estágio PAE).
- A4: Estudo e desenvolvimento da metodologia principal (modelagem).
- A5: Elaboração da monografia de qualificação (incluí propostas do projeto e revisão bibliográfica).
- A6: Defesa da Qualificação.
- A7: Extensão das abordagens selecionadas (metodologia alternativas).
- A8: Elaboração e execução de experimentos computacionais.
- A9: Análise de resultados.
- A10: Elaboração de contribuições técnicas e científicas (artigos, congressos, etc.).
- A11: Elaboração da Tese.
- A12: Defesa da Tese.

Na Tabela 1 propõe-se um cronograma para o desenvolvimento das atividades relacionadas ao projeto de pesquisa de doutorado, com previsão de execução até dezembro de 2029.

Tabela 1: Cronograma de atividades.

-	2026/1	2026/2	2027/1	2027/2	2028/1	2028/2	2029/1	2029/2
A1	X	X						
A2	X	X	X		X	X		
A3			X	X	X			
A4		X	X					
A5		X	X					
A6			X					
A7				X	X	X	X	
A8						X	X	
A9					X	X	X	
A10		X[1]	X[1]			X	X	X
A11						X	X	X
A12								X

[1] Contribuição referente aos resultados parciais da pesquisa, nesta etapa monografia, para publicação obrigatória para qualificação.

Referências Bibliográficas

AHUJA, R. K.; ORLIN, J. B. Inverse optimization. *Operations Research*, INFORMS, v. 49, n. 5, p. 771–783, out. 2001. ISSN 0030-364X.

ANSS. *ANS divulga dados econômico-financeiros relativos ao 3º trimestre de 2024*. dez. 2024. Disponível em: <https://www.gov.br/ans/pt-br/assuntos/noticias/numeros-do-setor/ans-divulga-dados-economico-financeiros-relativos-ao-3o-trimestre-de-2024>.

BARD, J. F.; PURNOMO, H. W. Preference scheduling for nurses using column generation. *European Journal of Operational Research*, v. 164, n. 2, p. 510–534, 2005. ISSN 0377-2217.

BERGH, J. Van den; BELIëN, J.; BRUECKER, P. D.; DEMEULEMEESTER, E.; BOECK, L. D. Personnel scheduling: A literature review. *European Journal of Operational Research*, v. 226, n. 3, p. 367–385, maio 2013. ISSN 0377-2217.

BLUM, C. Metaheuristics in combinatorial optimization: Overview and conceptual comparison. *ACM Computing Surveys*, v. 35, n. 3, 2003.

BURDETT, R. L.; KOZAN, E.; SINNOTT, M.; COOK, D.; TIAN, Y.-C. A mixed integer linear programing approach to perform hospital capacity assessments. *Expert Systems with Applications*, v. 77, p. 170–188, 2017. ISSN 0957-4174.

CHIARANDINI, M.; BIRATTARI, M.; SOCHA, K.; ROSSI-DORIA, O. An effective hybrid algorithm for university course timetabling. *Journal of Scheduling*, v. 9, n. 5, p. 403–432, out. 2006. ISSN 1099-1425.

CORDEAU, J.-F.; DESAULNIERS, G.; DESROSIERS, J.; SOLOMON, M. M.; SOUMIS, F. 7. vrp with time windows. In: ____. *The Vehicle Routing Problem*. Society for Industrial and Applied Mathematics, 2002. (Discrete Mathematics and Applications), p. 157–193. ISBN 978-0-89871-498-2. Disponível em: <https://epubs.siam.org/doi/10.1137/1.9780898718515.ch7>.

ERHARD, M.; SCHOENFELDER, J.; FüGENER, A.; BRUNNER, J. O. State of the art in physician scheduling. *European Journal of Operational Research*, v. 265, n. 1, p. 1–18, 2018. ISSN 0377-2217. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0377221717305787>.

ERNST, A. T.; JIANG, H.; KRISHNAMOORTHY, M.; SIER, D. Staff scheduling and rostering: A review of applications, methods and models. *European Journal of Operational Research*, v. 153, n. 1, p. 3–27, fev. 2004. ISSN 0377-2217.

EVEN, S.; ITAI, A.; SHAMIR, A. On the complexity of timetable and multicommodity flow problems. *SIAM Journal on Computing*, Society for Industrial and Applied Mathematics, v. 5, n. 4, p. 691–703, dez. 1976. ISSN 0097-5397.

GHOBADI, K.; MAHMOUDZADEH, H. Inferring linear feasible regions using inverse optimization. *European Journal of Operational Research*, v. 290, n. 3, p. 829–843, maio 2021. ISSN 0377-2217.

HEUBERGER, C. Inverse combinatorial optimization: A survey on problems, methods, and results. *Journal of Combinatorial Optimization*, v. 8, n. 3, p. 329–361, 2004. ISSN 1573-2886.

LIEBEL, G. et al. Análise dos gastos com diagnóstico por imagem no brasil. *Cadernos Saúde Coletiva*, Instituto de Estudos em Saúde Coletiva da Universidade Federal do Rio de Janeiro, v. 29, p. 453–463, dez. 2021. ISSN 1414-462X, 2358-291X.

Medicina S.A. *Brasileiros realizaram 2,4 bilhões de exames em 2023, alta de 11%*. ago. 2024. Disponível em: <https://medicinasa.com.br/exames-diagnostico-23/>.

OLSON, G.; DAVIS, A. M. Diagnosis and treatment of adults with community-acquired pneumonia. *JAMA*, v. 323, n. 9, p. 885–886, mar. 2020. ISSN 1538-3598.

ROBINSON, L.; CHEN, R. Scheduling doctors' appointments: Optimal and empirically-based heuristic policies. *IIE Transactions (Institute of Industrial Engineers)*, v. 35, n. 3, p. 295–307, 2003.

ROUSSEAU, L.-M.; PESANT, G.; GENDREAU, M. A general approach to the physician rostering problem. *Annals of Operations Research*, v. 115, n. 1, p. 193–205, set. 2002. ISSN 1572-9338.

TASSO, V. Y.; TOMAZELLA, C. P.; MARIOTTI, T.; SANTOS, M. O. d. Modelagem matemática para a alocação de médicos em unidades de diagnóstico por imagem. Galoá, 2024. Disponível em: <https://proceedings.science/sbpo/sbpo-2024/trabalhos/modelagem-matematica-para-a-alocacao-de-medicos-em-unidades-de-diagnostico-por-i?lang=pt-br>.

WOLSEY, L. A. *Integer Programming*. [S.l.]: John Wiley & Sons, 1998. Google-Books-ID: x7RvQgAACAAJ. ISBN 978-0-471-28366-9.

YASUI, S. et al. Importance of computed tomography imaging features for the diagnosis of autoimmune acute liver failure. *Hepatology Research*, v. 42, n. 1, p. 42–50, 2012. ISSN 1872-034X.